

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
КАФЕДРА ВТ

ОТЧЕТ
по лабораторной работе № 1
по дисциплине «Основы машинного обучения»
Тема: «Предобработка данных для машинного обучения»

Студенты гр. 3311

Сапронов К. Д.

Землякова С. А.

Кудрин П. В.

Преподаватель

Петруша П. Г.

Санкт-Петербург

2025

Цель работы: Получение и закрепление навыков предобработки данных для дальнейшего применения методов машинного обучения для решения задач.

Задание.

Самостоятельно выбрать набор сырых (не разобранных) данных на сайте [kaggle.com](https://www.kaggle.com) с следующими критериями:

- Число столбцов признаков – не менее 10;
- Число записей – не менее 10000;
- Набор данных имеет пропуски.

Очистить данные (удалить пропуски, нормализовать данные, удалить дубликаты).

Визуализировать значимые признаки с помощью таких методов как:

- Диаграммы рассеяния
- Ящики с усами
- Гистограммы

Проанализировать корреляцию данных (матрица корреляций)

Описание решения.


Был выбран датасет https://www.kaggle.com/datasets/rohanrao/air-quality-data-in-india?select=city_day.csv, ввиду большого количества записей, численных данных, а также наличия пропущенных значений.

Целевым признаком выберем AQI – индекс качества воздуха. Такие признаки как город и AQI_Bucket (интерпретация AQI) для прогноза использовать не будем. Численных признаков все равно остается много, выберем некоторые из них – PM2.5, PM10, CO, NO2, O3.

Основная работа была проделана в Google Colab, ссылка:


<https://colab.research.google.com/drive/1vKoSTMI2dp5VNTZpdWoxDI39Cj1sn0IK?usp=sharing>

В ходе работы были заполнены пропуски медианными значениями, нормализованы данные и удалены дубликаты. По полученным данным были получены следующие гистограммы и ящики с усами:




Ввиду большого количества пропусков в исходном наборе данных, мы получаем большое количество выбросов на ящиках с усами и плохо читаемые гистограммы.

Поэтому были удалены выбросы по правилу трех сигм, после обработки получились такие гистограммы и ящики:




На представлениях данных исчезли экстремальные выбросы и они стали более читаемыми.

Диаграммы рассеяния



Из представленных диаграмм наиболее интересны PM2.5/PM10, PM2.5/AQI и PM10/AQI, так как по ним прослеживается корреляция между парами значений. Для некоторых же параметров, например, для любого график O3 и другого параметра, тяжело проследить вообще какую либо корреляцию, а значит, скорее всего никакой зависимости между ними нет.

Матрица корреляции



Здесь мы видим подтверждение предположений о корреляции признаков по диаграммам рассеяния - пары PM2.5/PM10, PM2.5/AQI и PM10/AQI имеют достаточно высокий коэффициент корреляции. Ключевой параметр AQI наиболее коррелирует именно с признаками PM2.5 и PM10, что говорит о том, что основным источником загрязнения воздуха являются выбросы микрочастиц. Между признаками PM2.5 и PM10 корреляция - если в воздухе есть много микрочастиц одного размера, то скорее всего много и другого размера. Также видна сильная корреляция между веществами, содержащие общие элементы, такие как NO, NO2, NOx, NH3, а также такими веществами как Toulene, Benzene, Xylene, что может говорить об общей природе их выбросов.

Статистический анализ

Статистические функции были применены до нормализации данных для более наглядных результатов. Были выбраны функции `mean`, `std`, `min` и `max` для получения базовых параметров выборки, функции `shapiro` и `norm.fit` для анализа нормальности распределения, и функции `skew` и `kurtosis` для определения ассиметрии выборки.

По полученным результатам видим, что для всех столбцов параметр `sigma` (СКО) сравним со значением `mean` (средним), что говорит о большом разбросе данных. Параметры `skew` и `kurtosis`, а также малое значение `mean`, говорят нам о сильной правосторонней ассиметрии - это значит, что в выборке большая часть значений находится “слева” (то есть малы), но есть значительное количество экстремальных выбросов “вправо” (то есть очень больших значений).

Это также подтверждается полученными гистограммами и ящиками с усами - на гистограммах большинство значений находится в левой половине графика, а ящики с усами находятся снизу, что говорит о малом значении медианы, а также видно большое количество выбросов выше усов ящика.

Проверка на нормальность функциями `shapiro` (тест Шапиро) и `norm.fit` (тест Д'Агостино) выдают значение `p-value` равное нулю, что говорит о том, что выборка не распределена нормально.

Все эти характеристики соответствуют датасету - большую часть времени количество какого-то вещества в воздухе постоянно, но резко изменяется при выбросах каких-либо веществ в атмосферу - этим объясняется и наличие сильной ассиметрии, и отсутствие нормального распределения. А также Индия - достаточно крупная страна, и данные по воздуху между разными городами могут сильно отличаться, что также влияет на общую картину.

Выводы

В ходе выполнения лабораторной работы был проведен комплексный анализ и предварительная обработка выбранного набора данных. На начальном этапе были устранены пропуски в данных и удалены дублирующиеся записи. Для приведения признаков к единому масштабу выполнена нормализация числовых показателей. С помощью методов визуализации - диаграмм рассеяния, гистограмм и ящиков с усами - были выявлены основные закономерности в данных, а корреляционный анализ позволил определить взаимосвязи между признаками. Также были применены некоторые инструменты статистического анализа для определения вида распределения данных. В результате работы были получены и закреплены практические навыки предобработки данных, которые являются критически важным этапом для последующего построения эффективных моделей машинного обучения.