

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
КАФЕДРА ВТ

ОТЧЕТ
по лабораторной работе № 2
по дисциплине «Основы машинного обучения»
Тема: «Применения методов машинного обучения для решения задач
классификации»

Студенты гр. 3311

Сапронов К. Д.

Землякова С. А.

Кудрин П. В.

Преподаватель

Петруша П. Г.

Санкт-Петербург

2025

Цель работы: получение и закрепление навыков предобработки данных и применение методов машинного обучения для решения задач классификации.

Задание.

Набор данных берется из лабораторной работы №1.

Обучение моделей и подбор параметров (с использованием Grid Search):

- К-ближайших соседей (KNN)
- Машина опорных векторов (SVM)
- Дерево решений ИЛИ Случайный лес

Оценка моделей

- Оценка качества прогноза (precision/recall/f1-score/ROC-AUC)
- Визуализация дерева решений ИЛИ Визуализация Feature Importance для случайного леса

Описание решения.

Датасет: https://www.kaggle.com/datasets/rohanrao/air-quality-data-in-india?select=city_day.csv

Блокнот в Google Colab:


<https://colab.research.google.com/drive/1gqcTpd3W1glCrIPFUODLTP85ZdjIWzOD#scrollTo=xlBtPYxBKgBl>

Так как целевой признак AQI является численным, для выполнения классификации мы преобразуем его в бинарный по следующему принципу - если $AQI \geq 150$, то воздух “плохой” и значение равно 1, и, соответственно, если меньше 150, то воздух “хороший”, и значение 0.

Использовать будем методы KNN, SVM и Random Forest.

Grid Search

Для KNN Grid Search не применялся, так как достаточно и простого перебора значения k . По графику ниже видно, что после $k=5$ точность практически не растёт, поэтому используем $k=5$.



Для SVM уже применялся GridSearch, и из входных данных:

```
param_grid = {  
    'C': [1.0, 10.0, 15.0, 100.0],  
    'gamma': ['scale', 'auto', 0.01, 0.1, 1.0],  
    'kernel': ['rbf', 'linear']  
}
```

Лучшие параметры SVM: {'C': 15.0, 'gamma': 'scale', 'kernel': 'rbf'}

Для Random Forest тоже был применен GridSearch:

```
rf_params = {  
    'n_estimators': [50, 150, 300],  
    'max_depth': [5, 10, 15],
```

```
'min_samples_split': [2, 3],  
'min_samples_leaf': [1, 2]  
}
```

Лучшие параметры Random Forest: {'max_depth': 15, 'min_samples_leaf': 1, 'min_samples_split': 2, 'n_estimators': 150}

Метрики

Матрицы ошибок для каждой из моделей:

KNN:

Predicted	0	1	All
True			
0	5869	232	6101
1	449	2310	2759
All	6318	2542	8860

SVM:

Predicted	0	1	All
True			
0	5857	244	6101
1	402	2357	2759
All	6259	2601	8860

RF:

Predicted	0	1	All
True			
0	5837	264	6101
1	333	2426	2759
All	6170	2690	8860

Основные метрики:

KNN:

Accuracy: 0.92

Precision: 0.91

Recall: 0.84

F1-Score: 0.87

SVM:

Accuracy: 0.93

Precision: 0.91

Recall: 0.85

F1-Score: 0.88

RF:

Accuracy: 0.93


Precision: 0.90

Recall: 0.88


F1-Score: 0.89

ROC-AUC кривые


KNN: AUC = 0.959



SVM: AUC = 0.972



RF: AUC = 0.979



Также для Random Forest был получен список Feature Importance:

	Признак	Важность
0	PM2.5	0.42
1	PM10	0.16
6	CO	0.12
3	NO2	0.05
4	NOx	0.05
2	NO	0.04
8	O3	0.04
7	SO2	0.04
10	Toluene	0.03
5	NH3	0.03
9	Benzene	0.02
11	Xylene	0.01

Анализ.

Все три метода обучения показали хорошие результаты. Все модели показали отличные результаты accuracy (92-93%), высокий Precision (90-91% - когда модель предсказывает "плохой воздух", она почти всегда права), хороший Recall (84-88% - модель находит большинство случаев действительно плохого воздуха) и способность разделять классы (AUC 0.96-0.98).

Метод Random Forest показывает немного лучшие результаты за счёт более сложной модели. Также по матрицам ошибок заметим что основное различие приходится на False Negative - Random Forest заметно реже определяет "плохой" воздух как "хороший" (1 как 0).

При учете того, что при преобразовании мы получили неравные классы - соотношения классов 30/70 (где класс "1" — миноритарный), Accuracy может вводить в заблуждение. Модель, которая всегда предсказывает класс "0", получила бы Accuracy ~70%, но была бы бесполезна для обнаружения класса "1". F1-Score, будучи гармоническим средним Precision и Recall, лучше отображает реальную эффективность модели - в этом случае лидером также является Random Forest. По метрикам он имеет такую же Accuracy как и SVM, но чуть хуже Precision и лучший recall, что и отображается в лучшем значении f1.

Также с помощью RF были получены значимости признаков, которые совпали с выводами из матрицы корреляций из прошлой работой - основными факторами загрязнения воздуха являются PM2.5 и PM10, суммарно определяющие 58% прогноза.

Выводы

В ходе выполнения лабораторной работы было проведено обучение и сравнение трех моделей машинного обучения для классификации качества воздуха. На этапе предобработки данных целевая переменная AQI была преобразована в бинарный признак. Для моделей SVM и Random Forest был применен Grid Search для оптимизации гиперпараметров. Были получены оценки моделей и проведен анализ важности признаков для Random Forest. В результате работы были получены практические навыки построения и оценки моделей классификации.