

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
КАФЕДРА ВТ

ОТЧЕТ
по лабораторной работе № 3
по дисциплине «Основы машинного обучения»
Тема: «Применение методов машинного обучения для решения задач
кластеризации»

Студенты гр. 3311

Сапронов К. Д.

Землякова С. А.

Кудрин П. В.

Преподаватель

Петруша П. Г.

Санкт-Петербург

2025

Цель работы: получение и закрепление навыков предобработки данных и применение методов машинного обучения для решения задач кластеризации.

Задание.

Набор данных берется из лабораторной работы №1.

Обучение моделей и подбор параметров (где применимо):

- метод K-средних
- Иерархическая кластеризация
- DBSCAN
- Линейная регрессия
- LASSO
- Ридж-регрессия

Оценка моделей

- а. Экспертная оценка
- б. Сравнение разбиения на классы с помощью кластеризации
- с. Визуализация предсказанных значений

Описание решения.

Датасет: https://www.kaggle.com/datasets/rohanrao/air-quality-data-in-india?select=city_day.csv


Блокнот в Google Colab:

<https://colab.research.google.com/drive/19CHxXA5O3U8MtkxgUGlgLxNgk2UHXwj0?usp=sharing>

В ходе работы были использованы все 6 методов, предложенные в задании.


Методы кластеризации

Для К-Means был использован метод локтя.




Исходя из графика, было выбрано число кластеров 8

Визуализация кластеров:




Дендрограмма для иерархической кластеризации:




Визуализа

ция кластеров (также было выбрано 8):



Для DBSCAN был выбран параметр $\epsilon = 0.003$, при нем количество кластеров равно 9, что сопоставимо с 8 кластерами из прошлых методов. При изменении этого параметра это число заметно меняется - при увеличении мы быстро приходим к 1 кластеру, а при уменьшении количество кластеров начинает быстро увеличиваться.

Визуализация кластеров:



Анализ метрик

Для анализа качества кластеризации были использованы следующие метрики:

	Метод	Количество кластеров	Silhouette Score	Calinski-Harabasz	\
0	K-Means	8	0.2170	9484.2549	
1	Иерархическая	8	0.3156	7858.0036	
2	DBSCAN	9	0.5818	717.4606	
	Davies-Bouldin				
0			1.1482		
1			1.1714		
2			1.8432		

Silhouette score - показывает схожесть объектов внутри кластера по сравнению со схожестью с объектами из других кластеров. Другими словами, насколько четкие границы между кластерами. В нашем случае значения показывают что DBSCAN лучше разделил кластеры, в других же методах кластеры чаще перекрывают друг друга.

Calinski-Harabasz - измеряет плотность кластера. Чем больше значение, тем более кластер плотный. Заметим, что у DBSCAN на порядок ниже плотность - это значит, что кластеры в нем достаточно большие и “размазанные”.

Davies-Bouldin - сходство между кластерами их соседями. Чем ниже значение, тем более кластеры компактные и разделенные. DBSCAN опять заметно отличается от двух других методов - несмотря на хорошее разделение кластеров, мы снова видим худший результат, что скорее всего обусловлено низкой плотностью кластеров.

По визуализациям графиков мы видим ту же картину:

K-Means - кластеры (почти все) плотные, но часто имеют нечеткие границы.

Иерархическая - похожая картина, но кластеры чаще накладываются друг на друга.

DBSCAN - почти все точки состоят только в 2 кластерах, объединяющих все низкие значения признаков. Они слабо друг друга перекрывают, но имеют очень большой размер и включают в себя много выбросов, из-за чего имеют низкую плотность. Оставшиеся же кластеры также включают в себя в основном выбросы.

Регрессия и её анализ

Были использованы все три метода регрессии - линейная, LASSO и Ridge, а также регрессоры для методов из прошлой работы - KNN, SVM и RF.

Метрики:

Модель	R^2	MSE
Linear	0.8179	2904.6404
LASSO	0.8178	2905.3606
Ridge	0.7950	3268.7827
KNN	0.8629	2187.2271
SVM	0.8028	3144.9453
RF	0.8837	1854.7319

Из трех первых моделей хуже всего справился Ridge - это можно объяснить большими штрафами за ошибки, а в нашем датасете много выбросов, из-за чего модель получается хуже. Лучшие же результаты трех последних моделей можно объяснить использованием Grid Search, а из них лучшим вариантом ожидаемо оказался Random Forest, в прошлой работе он также показал лучший результат благодаря способности находить сложные нелинейные зависимости и работать с выбросами.

Также были получены коэффициенты признаков для разных моделей:

Признак	Linear	LASSO	Ridge
PM2.5	14840.5860	14831.4259	11625.9387
PM10	6437.8758	6407.3920	5572.3020
NO2	3513.9950	3507.3791	4378.4793
CO	13167.4899	13155.8566	11476.8165
O3	1572.6697	1530.0724	1488.6385

Самыми важными признаками оказались PM2.5, PM10 и CO, что соответствует результатам прошлых работ. Также заметим, что у Ridge коэффициенты в целом ниже чем у других двух моделей - это, опять таки, связано с увеличенными штрафами за ошибки, что привело к худшему результату модели.

Выводы

В ходе выполнения лабораторной работы было проведено комплексное сравнение шести методов машинного обучения - трех методов кластеризации и трех методов регрессии. Была выполнена визуализация кластеров и анализ метрик моделей. Также было проведено сравнение коэффициентов признаков. В результате работы были получены практические навыки применения различных методов машинного обучения для решения задач кластеризации и регрессии на реальных экологических данных.